# Compiladores Relatório do trabalho prático – Analisador Léxico

### Alline Santos Ferreira Arthur Miranda Moreira

#### 1. Introdução

Quando utilizamos um software não pensamos no que acontece em um computador para que o resultado final seja o programa e suas funções. Na disciplina de Compiladores, estamos aprendendo que existe um processo por trás do software que a partir de um código fonte, construído por um programador, há um programa que faz a tradução desse código, em um formato que o computador seja capaz de executar e, como efeito final dessa execução é exibido o programa para que o usuário final possa utilizar.

Na disciplina de Compiladores, aprendemos mais detalhadamente como essa tradução ocorre. Sabemos que a estrutura deste software é dividida em análise e síntese. Na primeira parte, o programa fonte passa por uma fase de análise da estrutura gramatical. Se ela estiver incorreta, conforme é definido pela linguagem de programação utilizada para sua construção, o compilador exibe mensagem de erro para que o programador possa identificar e corrigir. Uma vez que essa fase de análise é feita com sucesso, então, na segunda etapa, denominada síntese, o compilador constrói o programa a partir do reconhecimento das informações analisadas e, em seguida, gera o executável que é o programa utilizado pelo usuário final.

Este trabalho visa, entendermos na prática, o funcionamento do compilador. Para isso, o trabalho proposto na disciplina é dividido em três etapas: Analisador Léxico, Analisador Sintático, Analisador Semântico e Tabelas de Símbolos.

Neste relatório, iremos apresentar a construção da primeira etapa de um compilador que é o Analisador Léxico. É a etapa que identifica se a estrutura gramatical do software está lexicalmente correta. Sua função é ler um fluxo de caracteres que compõem o código fonte e os agrupar em sequências significativas denominadas por lexemas. Cada lexema, produzirá uma saída chamada de token que é utilizada na segunda etapa do trabalho que é a análise sintática. O token, tem o formato <nome-token, valor-atributo>. O nome-token é um símbolo abstrato usado durante a análise sintática, e o valor-atributo, aponta para uma tabela de símbolos referente a esse token. Essa tabela de símbolos é necessária para a análise semântica (3a. etapa do trabalho). E, ao final da construção das três etapas deste trabalho, compreenderemos na prática o funcionamento de um compilador.

## 2. Desenvolvimento

#### 2.2 Descrição da implementação

Para a implementação do Analisador Léxico, utilizamos a linguagem de programação Java. E para execução do programa é necessário que seja informado o caminho onde se encontra o arquivo de teste. Ao digitar o caminho válido, o arquivo é aberto pelo analisador léxico, que analisa os caracteres do arquivo fonte e retorna o token formado, a cada chamada da função nextToken(). Caso haja algum erro durante a formação dos tokens, o analisador lança uma exceção léxica. Para entender melhor, como executar o programa, a seguir iremos explicar em detalhes a construção de cada classe e sua função.

#### 2.2.1 Classes do programa

Para a construção deste analisador, foram desenvolvidas as seguintes classes: App, Lexer, Word, Num, Token e Tag.

A classe **Tag** define as constantes que representam os diferentes tipos de tokens. Já a classe **Token** é responsável por armazenar essas representações de forma padronizada.

A classe **Word** gerencia os lexemas relacionados a palavras reservadas, identificadores e operadores compostos como: &&, conforme definidos pela gramática do analisador. A classe **Num**, por sua vez, trata dos tokens numéricos reconhecidos durante a análise.

A lógica do analisador léxico está implementada na classe **Lexer**. É nessa classe que ocorre a leitura do código-fonte de teste, bem como a verificação de sua conformidade sintática e semântica com a estrutura gramatical definida. Caso seja detectado algum erro, o programa exibirá uma mensagem com a descrição do problema e a linha onde ele ocorreu, interrompendo a execução para que o programador possa corrigi-lo antes de tentar compilar novamente. Ou seja, nesta implementação não há recuperação de erro (erros são considerados fatais).

Por fim, a classe **App** contém o método main. Sua função é verificar se o arquivo de teste foi localizado. Se encontrado, a classe Lexer é chamada para iniciar a análise léxica; caso contrário, uma mensagem será exibida informando que o arquivo não foi encontrado. Essa classe contém um loop para ler todo o arquivo, e a cada iteração é impresso na tela o token lido. Foi utilizado um switch case para ler os os Tokens de operadores e pontuação (vírgula, ponto e vírgula, sinal de adição, entre outros).

Os códigos construídos nas classes: Tag, Word, Token, Num, foram inspirados no trabalho dos autores Alfred Aho, Monica Lam, Ravi Sethi e Jeffrey Ullman.

#### 3. Resultados

Para executarmos o programa a fim de avaliarmos a criação do Analisador Léxico, foi disponibilizado pela professora 5 arquivos testes. O objetivo era verificar se o compilador construído, reconheceria os erros, léxicos, semânticos e sintáticos existentes, identificando através de uma mensagem em qual linha houve o erro e abortando a execução. Em seguida, os erros seriam corrigidos pelo usuário e ao repetir a execução, ele deveria avaliar novamente e com sucesso. Nessa etapa, os únicos erros identificados devem ser os erros léxicos, relacionados à formação dos tokens, destacados de vermelho nos programas de teste.

A seguir mostraremos os resultados de execução de todos os arquivos testes. E outro teste feito pelos autores do trabalho.

#### 3.1 Início da execução

Informar o caminho onde está salvo o arquivo teste.

```
PS C:\Users\User\Desktop\Compiladores\TP1> ^C
PS C:\Users\User\Desktop\Compiladores\TP1> ^C
PS C:\Users\User\Desktop\Compiladores\TP1> C:; cd 'c:\Users\User\Desktop\Compiladores\TP1'; & 'C:\Program Files\Java\jdk-24\bin\java.exe' '--enable-preview' '-XX:
+ShowCodeDetailsInExceptionMessages' '-cp' 'C:\Users\User\AppData\Roaming\Code\User\workspaceStorage\434e07f8f4ec6c5bc0ea1509c15c3fe3\redhat.java\jdt_ws\TP1_6585ea
e4\bin' 'App'
--- Compilador ---
Digite o nome ou caminho para o arquivo fonte do programa......
```

### 3.2 Programas de entrada e saída do compilador

### **Teste do Programa 1:**

```
int: a,b,c;
float: result;
char: ch;

begin
out("Digite o valor de a:");
in (a);
out("Digite o valor de c:");
read (ch);
b = 10;
result = (a * ch)/(b 5  345.27);
out("O resultado e: ");
out(result);
result = result + ch;
end
```

```
Token lido: "Digite o valor de a:" , lirha: 7
Token lido: ) , lirha: 7
Token lido: ) , lirha: 8
Token lido: in , lirha: 8
Token lido: in , lirha: 8
Token lido: a , lirha: 8
Token lido: a , lirha: 8
Token lido: a , lirha: 8
Token lido: j, lirha: 8
Token lido: j, lirha: 8
Token lido: j, lirha: 9
Token lido: j, lirha: 10
Token lido: j, lirha: 11
Token lido: j, lirha: 12
Token lido: j, lirha: 14
Token lido: j, lirha: 15
Token lido: j, lirha: 16
Token lido: j, lirha: 10
Token
```

O programa é lido até chegar na linha 12, onde ocorre um erro devido um caractere inválido ('-'), no lugar de um sinal de subtração. Substituindo '-' por '-' no programa1.txt e executando novamente:

```
Token lido: ) , linha: 10
Token lido: j , linha: 11
Token lido: j , linha: 12
Token lido: j , linha: 13
Token lido: j , linha: 14
Token lido: j , linha: 15
Token lido: j , linha: 16
Token lido: j , linha: 16
Token lido: j , linha: 16
Token lido: j , linha: 15
Token lido: esult , linha: 15
Token lido: esult , linha: 15
Token lido: esult , linha: 15
Token lido: j , linha: 15
Token lido: esult , linha: 15
Token lido: enult - Flm de arquivo
```

O arquivo é processado até o final.

```
Tabela de símbolos:
{a=a, b=b, c=c, read=read, in=in, ch=ch, program=program, then=then, do=do, while=while, float=float, int=int, out=out, result=result, else=else, repeat=repeat, ch an=char, end=end, until=until, begin=begin, if=if}
PS C:\User\Desktop\Compiladores\TPl>
```

### Teste do Programa 2:

```
program
float: raio, area = 0.0;

begin
repeat
in(raio);
char: resposta;
if (raio > 0.0) then
area = 3.* raio * raio;
out (area);
end;
out ("Deseja continuar?);
in (resp);
until (resp == 'N' || resp == 'n');
end
```

```
Digite o nome ou caminho para o arquivo fonte do programa.......C:\\Users\\User\\Desktop\\Compiladores\\TP1\\codigos_fonte\\programa2.txt
Leitura de Tokens:
Token lido: program , linha: 1
Token lido: float , linha: 2
Token lido: raio , linha: 2
Token lido: raio , linha: 2
Token lido: raio , linha: 2
Token lido: area , linha: 2
```

A execução ocorre até a linha 2, onde é lido um caractere inválido ('\$'). Removendo '\$' no programa2.txt e executando novamente:

```
Digite o nome ou caminho para o arquivo fonte do programa.......C:\\Users\\User\\Desktop\\Compiladores\\TPI\\codigos_fonte\\programa2.txt Leitura de Tokens:
Token lido: program , linha: 1
Token lido: float , linha: 2
Token lido: i, linha: 2
Token lido: i, linha: 2
Token lido: j, linha: 5
Token lido: j, linha: 6
Token lido: j, linha: 7
Token lido: j, linha: 7
Token lido: j, linha: 8
Token lido: j, linha: 9
Token
```

A execução ocorre até a linha 9, onde é lido um erro por float mal formado (esperado um dígito após "3.). Removendo acrescentando um 0, de forma que fique "3.0" no programa2.txt e executando novamente:

```
Token lido: ; , linha: 2
Token lido: pegur , linha: 4
Token lido: peput , linha: 5
Token lido: peput , linha: 6
Token lido: (, linha: 6
Token lido: (, linha: 6
Token lido: ), linha: 6
Token lido: , linha: 7
Token lido: , linha: 8
Token lido: a, linha: 8
Token lido: a, linha: 9
Token lido: a, linha: 9
Token lido: i, linha: 9
Token lido: j, linha: 10
Token lido: j, linha: 12
Token lido: j, linha: 10
Token lid
```

A execução ocorre até a linha 12, onde é lido um literal contendo quebra de linha, gerando um erro. Fechando aspas no programa2.txt, de forma que a linha 12 se torne: out ("Deseja continuar?");, e executando novamente:

```
Digite o nome ou caminho para o arquivo fonte do programa......C:\User\\Desktop\\Compiladores\\TP1\\codigos_fonte\\programa2.txt Leitura de rokens:
Token lido: program , linha: 1
Token lido: float , linha: 2
Token lido: :, linha: 6
Token lido: in , linha: 6
Token lido: |, linha: 6
Token lido: |, linha: 6
Token lido: |, linha: 7
Token lido: |, linha: 7
Token lido: |, linha: 7
Token lido: |, linha: 8
Token lido: |, linha: 9
Token
```

```
Token lido: ", linha: 9
Token lido: ", linha: 9
Token lido: ", linha: 9
Token lido: raio, linha: 10
Token lido: raio, linha: 10
Token lido: (, linha: 10
Token lido: ), linha: 10
Token lido: (, linha: 10
Token lido: ), linha: 10
Token lido: (, linha: 10
Token lido: ), linha: 11
Token lido: (, linha: 11
Token lido: ), linha: 11
Token lido: (, linha: 12
Token lido: ), linha: 12
Token lido: (, linha: 13
Token lido: ), linha: 13
Token lido: (, linha: 13
Token lido: ), linha: 13
Token lido: (, linha: 13
Token lido: ), linha: 13
Token lido: (, linha: 13
Token lido: (, linha: 13
Token lido: (, linha: 14
Token lido: millo: milha: 14
Token lido: millo: milha: 14
Token lido: milha: 14
Token lido: millo: milha: 14
Token lido: milha: 16
Token lid
```

O arquivo é processado até o final.

### **Teste do Programa 3:**

```
program
```

```
int: a, b, aux;
begin
  in (a);
  in(b);
  if (a>b) then
    int aux;
    aux = b;
    b = a;
    a = aux
  end;
  out(a;
  out(b)
  end
```

```
Digite o nome ou caminho para o arquivo fonte do programa.......C:\\Users\\User\\Desktop\\Compiladores\\TP1\\codigos_fonte\\programa.txt Leitura de Tokens:
Token lidos program , linha: 1
Token lidos program , linha: 3
Token lidos , linha: 6
Token lidos , linha: 7
Token lidos , linha: 8
Token lidos , linha: 9
Token lidos , linha: 9
Token lidos , linha: 9
Token lidos , linha: 10
```

O arquivo é processado até o final. O programa até possui erros, como a ausência de ponto e vírgula e parênteses não fechado, mas trata-se de erro sintático, não léxico, de forma que o analisador léxico não percebe erro algum.

### Teste do Programa 4:

```
program
a, b, c, maior, outro: int;
begin
repeat
out("A");
in(a);
out("B");
in(b);
out("C");
```

```
in(c);
 %Verifica o maior
 if ((a>b) and (a>c)) end
    maior = a
 else
    if (b>c) then
      maior = b;
    else
       maior = c
    end
 end;
 out("Maior valor: "");
 out (maior);
 out ("Outro? ");
 in(outro);
until (outro == 0)
end
```

A execução ocorre até a linha 9, onde é lido um literal contendo quebra de linha, gerando um erro. Removendo a aspas a mais no programa4.txt, de forma que a linha 9 se torne: out("Maior valor: ");, e executando novamente:

```
Token lido: out , linha: 9
Token lido: ( , linha: 9
Token lido: "C" , linha: 9
Token lido: ) , linha: 9
Token lido: ) , linha: 9
  Token 11do: ) , Inma: 9
Token lido: ; , linha: 9
Token lido: in , linha: 10
Token lido: ( , linha: 10
Token lido: ( , linha: 10
Token lido: ) , linha: 10
Token lido: ) , linha: 10
    Token lido: ;
Token lido: if
                                                           , linha:
                                                                                             10
   Token lido: if , linha: 12
Token lido: ( , linha: 12
Token lido: ( , linha: 12
    Token lido: a , linha:
                                                                                            12
    Token lido: > ,
Token lido: b ,
                                                                 linha: 12
linha: 12
    Token lido: ) , linha: 12
Token lido: and , linha: 12
Token lido: ( , linha: 12
 Token lido: (, linha: 12
Token lido: (, linha: 12
Token lido: o, linha: 12
Token lido: c, linha: 12
Token lido: ), linha: 12
Token lido: ), linha: 12
Token lido: ), linha: 12
Token lido: end, linha: 12
Token lido: end, linha: 13
Token lido: end, linha: 13
Token lido: e, linha: 13
Token lido: else, linha: 15
Token lido: if, linha: 16
Token lido: (, linha: 16
Token lido: b, linha: 16
Token lido: c, linha: 16
Token lido: c, linha: 16
Token lido: h, linha: 16
  Token lido: dien , linha: 17
Token lido: = , linha: 17
Token lido: b , linha: 17
Token lido: ; , linha: 17
Token lido: else , linha: 19
```

```
Token lido: j, linha: 17

Token lido: jets, linha: 19

Token lido: maior , linha: 20

Token lido: maior , linha: 20

Token lido: c, linha: 20

Token lido: c, linha: 20

Token lido: c, linha: 21

Token lido: c, linha: 21

Token lido: c, linha: 22

Token lido: out, linha: 23

Token lido: j, linha: 24

Token lido: j, linha: 25

Token lido: j, linha: 26

Token lido: j, linha: 27

Token lido: j, linha: 27

Token lido: j, linha: 27

Token lido: mult - Fim de arquivo

Token lido: mult - Fim de arquivo

Token lido: mult - Fim de arquivo

Token lido: end, linha: 27

Token lido: end, linha: 28

Token lido: end, linha: 27

Token lido: end, linha: 28

Token lido: end, linha: 27

Token lido: end, linha: 27

Token lido: end, linha: 28

Token lido: end, l
```

O arquivo é processado até o final. Novamente, existem outros erros, mas não são erros léxicos.

### **Teste do Programa 5:**

```
programa
declare
  inteiro: pontuacao, pontuacaoMaxina, disponibilidade;
  char: pontuacaoMinima
begin
  disponibilidade = 'S';
  pontuacaoMinima = 50;
  pontuacaoMaxima = 100;
  out("Pontuacao Candidato: ");
  in(pontuação);
  out("Disponibilidade Candidato: ");
  in(disponibilidade);
  { Comentario
  grande
  while (pontuação<=pontuacaoMaxima) do
    int: cont;
    cont = cont + 1;
    if ((pontuação > pontuacaoMinima) && (disponibilidade==1)) then
       out("Candidato aprovado")
    else
       out("Candidato reprovado")
    end
    out("Pontuacao Candidato: ");
    in(pontuação);
    out("Disponibilidade
  Candidato: ");
    in(disponibilidade);
```

out (cont);

```
Token lido: ; , linha: 3
Token lido: , linha: 4
Token lido: , linha: 4
Token lido: , linha: 4
Token lido: portusacaminima, linha: 4
Token lido: begin, linha: 5
Token lido: begin, linha: 5
Token lido: begin, linha: 5
Token lido: , linha: 6
Token lido: , linha: 7
Token lido: 50 , linha: 7
Token lido: 50 , linha: 7
Token lido: jo, linha: 8
Token lido: jo, linha: 9
Token lido: jo, linha: 10
Token lido: jo, linha: 11
Token lido: jo, linha: 12
Token lido: jo, linha: 14
```

O compilador lê um '{', que inicia um comentário de mais de uma linha, de forma que todos os caracteres lidos a seguir são ignorados. Porém, o comentário não é fechado, causando um erro. Fechando o comentário:

```
{ Comentario grande}
```

E executando novamente:

```
Token lido: ; , linha: 9
Token lido: in , linha: 10
Token lido: (, linha: 10
Token lido: portuacao , linha: 10
Token lido: portuacao , linha: 10
Token lido: j, linha: 10
Token lido: j, linha: 10
Token lido: j, linha: 11
Token lido: (, linha: 11
Token lido: (, linha: 11
Token lido: j, linha: 12
Token lido: (, linha: 12
Token lido: j, linha: 12
Token lido: j, linha: 12
Token lido: kilon lido: kilon lido: kilon lido: j, linha: 12
Token lido: kilon lido: kil
```

```
Token lido: if , linha: 19
Token lido: (, linha: 19
Token lido: (, linha: 19
Token lido: (, linha: 19
Token lido: pontuação, linha: 19
Token lido: j, linha: 19
Token lido: de lido: linha: 19
Token lido: de lido: de lido: linha: 19
Token lido: disponibilidade, linha: 19
Token lido: disponibilidade, linha: 19
Token lido: linha: 19
Token lido: j, linha: 19
Token lido: dut, linha: 19
Token lido: dut, linha: 20
Token lido: dut, linha: 20
Token lido: dut, linha: 20
Token lido: out, linha: 20
Token lido: out, linha: 22
Token lido: out, linha: 22
Token lido: out, linha: 22
Token lido: out, linha: 25
Token lido: out, linha: 25
Token lido: j, linha: 26
Token lido: j, linha: 27
Token lido: j, linha: 28
Token lido: j, linha: 29
Token lido: j, linha: 20
Token lido: j, linha: 20
Token lido: j, linha:
```

A execução ocorre até a linha 27, onde é lido um literal contendo quebra de linha. Removendo a quebra de linha, de forma que a linha se torne: out("Disponibilidade Candidato: "); , e executando novamente:

```
Token lido: ; , lirha: 10
Token lido: out , lirha: 11
Token lido: (, lirha: 11
Token lido: ), lirha: 11
Token lido: j, lirha: 11
Token lido: j, lirha: 11
Token lido: j, lirha: 12
Token lido: in, lirha: 12
Token lido: in, lirha: 12
Token lido: isponibilidade , lirha: 12
Token lido: isponibilidade , lirha: 12
Token lido: isponibilidade , lirha: 12
Token lido: j, lirha: 12
Token lido: j, lirha: 16
Token lido: j, lirha: 18
Token lido: j, lirha: 19
Token lido: j, lirha: 1
```

```
Token lido: ) , linha: 19
Token lido: & , linha: 19
Token lido: (, linha: 19
Token lido: (, linha: 19
Token lido: disponibilidade , linha: 19
Token lido: j , linha: 10
Token lido: (, linha: 20
Token lido: j , linha: 20
Token lido: j , linha: 20
Token lido: j , linha: 22
Token lido: j , linha: 23
Token lido: j , linha: 25
Token lido: out , linha: 25
Token lido: out , linha: 25
Token lido: out , linha: 25
Token lido: j , linha: 26
Token lido: j , linha: 27
Token lido: j , linha: 26
Token lido: j , linha: 27
Token lido: j , linha: 28
Token lido: j , linha: 30
Token lido: out , linha: 30
Token lido: out , linha: 31
```

O arquivo é processado até o final.

#### Teste do Programa 6:

```
programa
int: a

comeca
out(Digite o valor de a:);
termina
```

A motivação deste programa é testar os erros envolvendo variáveis do tipo char.

Ocorreu um erro após a leitura de 'D , pois é esperado um fecha aspas após a leitura de um único caractere, para variáveis do tipo char. Substituindo as aspas simples por aspas duplas, de forma que o programa fique:

```
programa
int: a

comeca
out("Digite o valor de a:");
termina
```

E executando novamente:

```
Digite o nome ou caminho para o arquivo fonte do programa.......C:\\Users\\User\\Desktop\\Compiladores\\TP1\\codigos_fonte\\programa6.txt leitura de Tokens:
Token lido: programa , linha: 1
Token lido: int , linha: 2
Token lido: a , linha: 2
Token lido: out , linha: 2
Token lido: out , linha: 5
Token lido: out , linha: 5
Token lido: (, linha: 5
Token lido: () , linha: 5
Token lido: ) , linha: 5
Token lido: ) , linha: 5
Token lido: termina , linha: 6
Token lido: termina , linha: 6
Token lido: termina , linha: 6
Token lido: null - Fim de arquivo

Tabela de simbolos:
{a=a, in=in, programa=programa, program=program, then=then, do=do, while=while, float=float, int=int, out=out, termina=termina, else=else, repeat=repeat, char=char, end=end, until=until, begin=begin, if=if, comeca=comeca}
PS C:\Users\User\Desktop\Compiladores\TP1>
```

A execução ocorre sem erros.

#### 4. Conclusão

Entender o funcionamento de um compilador é importante para os alunos que pretendem atuar na área da computação. Saber que, ao escrever um programa é necessário entender que cada linguagem de programação tem uma gramática própria e durante a compilação do programa, será avaliado se a estrutura do seu programa está coerente com análise sintática e semântica dessa gramática, é fundamental para compreender até mesmo a origem dos erros reportados, durante a fase de compilação de um programa que está sendo construído.

Na construção deste trabalho, o aluno pode vivenciar na prática, como é feito a Análise Léxica que é a primeira fase para o funcionamento de um compilador.

#### 5. Referência Bibliográfica

1. AHO, A. V. Jeffrey; Sethi, R.; Lam, MS (2008). **Compiladores. Princípios, técnicas e ferramentas.** São Paulo: Addison-Wesley, Pearson.